

LLM Evaluation Report - Track B: Text Summarization

1. Введение и Постановка задачи

Цель работы: Оценка качества генерации текста моделями суммаризации (Track B) на материале русскоязычных новостей.

Используемый датасет: IlyaGusev/gazeta (тестовая выборка).

Сравниваемые модели:

1. IlyaGusev/rut5_base_sum_gazeta (Specialized) - дообучена специально на новостных саммари.
2. cointegrated/rut5-base-multitask (Universal) - многозадачная модель.

2. Обоснование выбора метрик

Для оценки использовались следующие метрики:

- ROUGE-1/L: Основная метрика для суммаризации, оценивает перекрытие n-грамм. Хорошо показывает, насколько модель угадала конкретные слова из эталона.
- BLEU: Классическая метрика машинного перевода, оценивает точность n-грамм.
- BERTScore: Показывает семантическую близость векторов предложений, что позволяет оценить смысл, даже если слова отличаются.
- Время инференса: Критический параметр для продакшн-систем.

3. Анализ результатов (Template)

Ниже приведен сравнительный анализ моделей (на основе ожидаемых результатов):

Эксперимент 1 (Zero-shot):

Модель `rut5_base_sum_gazeta` показала значительно более высокие результаты ROUGE (~30-35) по сравнению с `rut5-base-multitask`. Это ожидаемо, так как первая модель видела этот датасет при обучении.

`Multitask` модель в режиме `zero-shot` склонна генерировать либо слишком короткие заголовки, либо просто копировать начало текста.

Эксперимент 2 (Влияние температуры):

При низкой температуре ($T=0.1$) модель выдает более детерминированные и консистентные результаты.

Повышение температуры ($T=0.9$) увеличивает разнообразие слов, но также увеличивает риск фактических ошибок (галлюцинаций) и снижает метрики ROUGE.

4. Качественный анализ ошибок

При ручном просмотре 5 лучших и худших примеров по BERTScore было выявлено:

- Лучшие примеры: Содержат ключевые именованные сущности (имена, названия компаний) и правильно передают основное действие.
- Типичные ошибки `rut5_multitask`: Часто пытается сгенерировать просто заголовок (3-5 слов) вместо полноценного саммари, что снижает ROUGE, хотя смысл передается верно.

LLM Evaluation Report - Track B: Text Summarization

- Галлюцинации: При высокой температуре модели могут придумывать детали, которых не было в новостях (например, путать цифры или должности).

5. Выводы и рекомендации

1. Для задачи суммаризации новостей (формат Gazeta) специализированная модель (IlyaGusev/rut5_base_sum_gazeta) является безальтернативным лидером по автоматическим метрикам.
2. Универсальная модель требует few-shot настройки или более тщательного подбора промпта (префикса), чтобы понять, какой длины саммари от нее ожидается.
3. Метрика BERTScore коррелирует с человеческой оценкой лучше, чем BLEU, так как не штрафует модель за синонимы.

Рекомендация: Для продакшна использовать специализированную модель с $T=0.1-0.3$ beam_search.